

1. Détection de fraude dans les transactions financières en temps réel

Contexte business

Les banques et fintechs traitent des millions de transactions chaque jour. La détection rapide de fraude est essentielle pour réduire les pertes financières et protéger les clients.

Les systèmes modernes utilisent **Big Data et streaming analytics** pour analyser les transactions en temps réel.

Objectif

Construire un système capable de détecter **des transactions frauduleuses en temps réel**.

Pipeline Big Data

Transaction dataset → Kafka (streaming) → Spark Streaming → stockage Data Lake → modèle ML → dashboard fraude

Technologies

- Kafka
- Apache Spark Streaming
- Hadoop / S3
- Python (Scikit-learn)
- Elasticsearch
- Grafana

Source de données

Credit Card Fraud Dataset

<https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>

Livrables

- Architecture Big Data
- Pipeline streaming
- Modèle de détection fraude

- Dashboard fraude temps réel
- Rapport d'analyse

2. Analyse Big Data de la satisfaction client sur les réseaux sociaux (NLP)

Contexte business

Les entreprises surveillent les réseaux sociaux pour comprendre **l'image de marque et la satisfaction client**.

Le traitement automatique du langage naturel (NLP) permet d'analyser les opinions clients à grande échelle.

Objectif

Construire un système d'analyse de **sentiment client en temps réel**.

Pipeline

API tweets → Kafka → Spark NLP → Data Lake → dashboard sentiment

Technologies

- Twitter API
- Kafka
- Spark NLP
- Python
- Elasticsearch
- Grafana

Source de données

Sentiment140 dataset

<https://www.kaggle.com/datasets/kazanova/sentiment140>

Livrables

- Pipeline collecte données

- Analyse sentiment
- Dashboard réputation
- Rapport marketing insights

3. Plateforme Big Data de monitoring intelligent d'infrastructure IT (AIOps)

Contexte business

Les systèmes informatiques produisent des **millions de logs et métriques**. L'analyse automatique permet de détecter les anomalies avant qu'un incident ne se produise.

C'est le principe du **AIOps (Artificial Intelligence for IT Operations)**.

Objectif

Construire une plateforme de monitoring intelligent capable de détecter des anomalies dans les logs systèmes.

Pipeline

Logs → Kafka → Spark → stockage → détection anomalies → dashboard monitoring

Technologies

- Filebeat / Fluentd
- Kafka
- Spark
- Elasticsearch
- Grafana
- Python ML

Source de données

Loghub dataset

<https://github.com/logpai/loghub>

Livrables

- Pipeline ingestion logs
- Modèle détection anomalies
- Dashboard incidents
- Simulation incident IT

4. Prédiction de la demande produit dans le retail (Demand Forecasting)

Contexte business

Les entreprises utilisent Big Data pour **anticiper la demande produit** et optimiser leurs stocks.

Une mauvaise prévision entraîne rupture de stock ou surstock.

Objectif

Construire un système de **prédiction de ventes** basé sur l'analyse **Big Data**.

Pipeline

Ventes → Data Lake → Spark ML → forecasting → dashboard

Technologies

- Hadoop
- Spark MLlib
- Python
- Airflow
- Grafana

Source de données

Online Retail Dataset

<https://archive.ics.uci.edu/ml/datasets/online+retail>

Livrables

- Pipeline data

- Modèle prévision
- Dashboard prévisions
- Rapport optimisation stocks

5. Analyse Big Data du trafic urbain pour villes intelligentes

Contexte

Les villes intelligentes utilisent les données pour améliorer la circulation et réduire la congestion.

Objectif

Analyser le trafic routier et identifier les périodes de congestion.

Pipeline

Capteurs trafic → streaming → analyse → stockage → dashboard

Technologies

- Kafka
- Spark
- PostgreSQL
- Grafana

Source de données

Metro Interstate Traffic Volume Dataset

<https://archive.ics.uci.edu/ml/datasets/metro+interstate+traffic+volume>

Livrables

- Pipeline Big Data trafic
- Analyse congestion
- Dashboard trafic
- Recommandations mobilité

6. Système de recommandation de contenu (films ou produits)

Contexte business

Les plateformes comme Netflix ou Amazon utilisent Big Data pour recommander du contenu aux utilisateurs.

Objectif

Construire un système de recommandation basé sur les préférences utilisateurs.

Pipeline

Data utilisateurs → Data Lake → Spark ML → moteur recommandation → API → dashboard

Technologies

- Spark MLlib
- Hadoop
- Python
- Grafana

Source de données

MovieLens dataset

<https://grouplens.org/datasets/movielens/>

Livrables

- Pipeline données
- Algorithme recommandation
- API recommandation
- Dashboard utilisation

7. Plateforme Big Data d'analyse des ventes e-commerce

Contexte business

Les entreprises e-commerce analysent les données pour comprendre les comportements d'achat et améliorer leurs revenus.

Objectif

Construire une plateforme d'analyse des ventes avec visualisation des tendances.

Pipeline

Logs e-commerce → ingestion → Data Lake → analyse Spark → dashboard

Technologies

- Hadoop
- Spark
- Python
- Grafana
- Elasticsearch

Source de données

E-commerce dataset

<https://www.kaggle.com/datasets/carrie1/ecommerce-data>

Livrables

- Pipeline données ventes
- Analyse comportement client
- Dashboard analytics
- Rapport business

8. Détection d'anomalies dans les performances applicatives (APM)

Contexte business

Les entreprises doivent surveiller les performances des applications pour garantir une bonne expérience utilisateur.

Objectif

Détecter automatiquement les anomalies de performance applicative.

Pipeline

Metrics → streaming → analyse ML → alerting → dashboard

Technologies

- Prometheus
- Kafka
- Spark
- Grafana

Source de données

Application monitoring dataset

<https://github.com/logpai/loghub/tree/master/HDFS>

Livrables

- Pipeline monitoring
- Détection anomalies
- Dashboard performance
- Rapport analyse

9. Analyse Big Data de la consommation énergétique

Contexte business

Les entreprises et villes intelligentes analysent la consommation énergétique pour optimiser les ressources.

Objectif

Analyser les tendances de consommation et prédire les pics.

Pipeline

Smart meter data → Data Lake → analyse Spark → ML forecasting → dashboard

Technologies

- Hadoop
- Spark
- Python
- Grafana

Source de données

Energy consumption dataset

<https://archive.ics.uci.edu/ml/datasets/individual+household+electric+power+consumption>

Livrables

- Pipeline data énergétique
- Analyse consommation
- Modèle prédictif
- Dashboard énergétique

10. Génération automatique de rapports business en langage naturel (NLP Reporting)

Contexte business

Les dirigeants veulent comprendre les données rapidement. Les systèmes modernes génèrent automatiquement des **rapports en langage naturel** à partir des données.

Objectif

Construire un système capable de générer des **rapports business automatiques**.

Exemple :

"Les ventes ont augmenté de 12% dans la région Ouest ce trimestre."

Pipeline

Data → analytics → NLP generation → dashboard

Technologies

- Spark
- Python
- NLTK / Transformers
- Grafana

Source de données

Sales forecasting dataset

<https://www.kaggle.com/datasets/rohitsahoo/sales-forecasting>

Livrables

- Pipeline analytics
- Génération rapports automatiques
- Dashboard
- Rapport final

11. Analyse Big Data de la détection de churn client (Customer Churn Prediction)

Contexte business

Les entreprises (télécom, banques, streaming) perdent chaque année une partie de leurs clients. Identifier **les clients susceptibles de quitter le service** permet de mettre en place des actions de rétention.

Objectif

Construire un système de **prédiction de churn client** basé sur l'analyse Big Data.

Pipeline

Données clients → ingestion → Data Lake → traitement Spark → modèle ML → dashboard churn

Technologies

- Apache Kafka (ingestion)
- Apache Spark
- Hadoop / S3
- Python (Scikit-learn)
- Grafana / Kibana

Source de données

Telco Customer Churn Dataset

<https://www.kaggle.com/datasets/blastchar/telco-customer-churn>

Livrables

- Pipeline Big Data
- Modèle de prédiction churn
- Segmentation clients
- Dashboard churn analysis
- Rapport recommandations business

12. Plateforme Big Data d'analyse des données de transport aérien

Contexte business

Les compagnies aériennes et les autorités de transport analysent les données de vols pour améliorer la ponctualité et optimiser les opérations.

Objectif

Analyser les retards de vols et identifier les facteurs principaux.

Pipeline

Données vols → ingestion → Data Lake → analyse Spark → visualisation

Technologies

- Apache Spark
- Hadoop
- Python
- Grafana / Kibana

Source de données

US Flights Dataset

<https://www.kaggle.com/datasets/usdot/flight-delays>

Livrables

- Pipeline d'analyse des vols
- Analyse causes retards
- Dashboard performance aérienne
- Rapport insights opérationnels

13. Analyse Big Data des tendances du marché de l'emploi

Contexte business

Les entreprises et gouvernements analysent les données du marché du travail pour comprendre les **compétences les plus demandées** et anticiper les besoins futurs.

Objectif

Construire une plateforme d'analyse des **offres d'emploi et des compétences demandées**.

Pipeline

Données offres → ingestion → traitement NLP → analyse tendances → dashboard

Technologies

- Apache Spark
- Python NLP
- Elasticsearch
- Grafana

Source de données

Job postings dataset

<https://www.kaggle.com/datasets/promptcloud/job-posting-dataset>

Livrables

- Pipeline collecte et analyse
- Analyse compétences demandées
- Dashboard tendances emploi
- Rapport insights marché

14. Analyse Big Data des accidents de la route

Contexte business

Les gouvernements utilisent les données d'accidents pour améliorer la sécurité routière et identifier les zones dangereuses.

Objectif

Analyser les causes principales des accidents et identifier les zones à risque.

Pipeline

Données accidents → Data Lake → traitement Spark → analyse géographique → dashboard

Technologies

- Apache Spark
- Hadoop
- Python
- Grafana
- PostgreSQL

Source de données

US Accidents Dataset

<https://www.kaggle.com/datasets/sobhanmoosavi/us-accidents>

Livrables

- Pipeline Big Data
- Analyse causes accidents
- Cartographie zones à risque
- Dashboard sécurité routière
- Rapport recommandations

15. Analyse Big Data des tendances du marché des cryptomonnaies

Contexte business

Les marchés financiers génèrent de grandes quantités de données. Les investisseurs utilisent Big Data pour analyser les tendances et prédire les mouvements du marché.

Objectif

Construire une plateforme d'analyse des **prix et volumes de cryptomonnaies**.

Pipeline

API crypto → streaming → Data Lake → analyse Spark → dashboard

Technologies

- API Crypto (CoinGecko / CryptoCompare)

- Kafka
- Spark
- Python
- Grafana

Source de données

Crypto market dataset

<https://www.kaggle.com/datasets/sudalairajkumar/cryptocurrencypricehistory>

Livrables

- Pipeline collecte données crypto
- Analyse tendances
- Modèle prédiction prix
- Dashboard crypto analytics
- Rapport insights financiers

Livrables généraux attendus pour chaque groupe

Chaque groupe devra produire :

1. Architecture Big Data

Diagramme complet du pipeline

2. Implémentation technique

- ingestion
- stockage distribué
- traitement

3. Analyse IA / analytics

4. Dashboard de visualisation

Grafana / Kibana

5. Rapport final

- contexte business
- architecture
- résultats
- démonstration